Descrição Geral:

Na presente entrega, pretende-se que os alunos desenvolvam as fases seguintes do modelo CRISP-DM **Entendimento dos Dados** (*Data Understanding*) e **Preparação dos Dados** (*Data Preparation*) aplicadas ao mesmo problema definido na entrega anterior.

Partindo do tema, problema e datasets já seleccionados, o objectivo desta etapa é analisar detalhadamente os dados recolhidos, avaliar a sua qualidade, realizar limpeza e transformação básicas, e produzir um dataset final pronto para modelação.

Não devem ainda construir modelos, validar performance ou comparar algoritmos - nesta fase apenas se prepara o "data asset" analítico.

Poderá utilizar outras frameworks de exploração de dados como scikit learn, google colab, Orange ML, ou outra, no trabalho final deverá implementar esta fase no AWS SageMaker.

A proposta deve ser entregue em formato PDF, máximo 4 páginas.

Tarefas a Realizar:

1. **Exploração dos Dados (Data Understanding)**

Para cada dataset recolhido:

- Descrever o conteúdo e as variáveis relevantes
- Apresentar estatísticas descritivas básicas (mínimo, máximo, média, desvio padrão, etc.)
- Identificar tipos de variáveis (numéricas, categóricas, datas, textos...)
- Apresentar visualizações exploratórias simples (histogramas, boxplots, barras, contagens)
- Identificar outliers, valores em falta, inconsistências e potenciais problemas de qualidade

(Nota: tabelas ou gráficos podem ser incluídos no anexo / apêndice se necessário)

2. **Avaliação da Qualidade dos Dados**

Avaliar pontos como:

- volume vs suficiência dos dados
- missing values
- redundância / duplicados
- ruído / erros de entrada
- balanceamento das classes (se aplicável)

Deverá ser apresentada uma tabela resumo da qualidade dos dados com conclusões objectivas.

3. **Preparação dos Dados (Data Preparation)**

Descrever e justificar as transformações aplicadas para construir o *dataset final*:

- limpeza / remoção de registos
- engenharia de features simples (ex.: derivação de datas, binning, extração de texto)
- normalização / padronização (se aplicada)
- codificação de variáveis categóricas (one-hot, label encoding, etc.)
- junção / integração de datasets
- definição da tabela final (features vs target, se já aplicável ao caso)

Deverá ser apresentada a *versão final das variáveis* com nome, tipo e descrição funcional.