

Analítica para Big Data,

Mestrado em Business Intelligence & Analytics

Relatório do Projeto de Grupo

Rui Filipe Parada, 2211025

Índice

Introdução 3
Tecnologias e Ferramentas de Suporte 4
Ciclo de Processamento de Dados 5
Camada Bronze: fase de ingestão de dados em bruto 5
Camada Silver: fase de limpeza, normalização e estruturação 6
Camada Gold: métricas e KPIs 7
Rotinas de sincronização e atualização 9
Interfaces Visuais 10
Modelo Preditivo e Análise 11
Conclusão 13
Referências 13
Anexos 14

Introdução

No âmbito da unidade curricular de Analítica para Big Data, o presente projeto académico visa o desenvolvimento e a implementação de um pipeline estruturado para a recolha, tratamento, armazenamento e modelação preditiva de dados meteorológicos históricos. Embora o volume total de dados gerido nesta fase inicial não atinja a escala estrita de *Big Data* em termos de volumetria isolada, a arquitetura da solução foi inteiramente desenhada e operacionalizada utilizando tecnologias do ecossistema de computação distribuída, garantindo a escalabilidade do sistema para horizontes temporais mais alargados.

O desenho experimental deste trabalho assenta na extração automatizada de dados meteorológicos através da API *Weatherstack* (recorrendo ao seu plano premium), cobrindo de forma sistemática os 18 distritos de Portugal continental. O histórico cronológico tem como ponto de partida o dia 01-01-2025, estando o sistema dotado de um mecanismo de atualização incremental para a incorporação contínua de novas observações diárias. A partir desta base de dados em bruto, o objetivo central consiste na derivação de um ecossistema de Indicadores Chave de Desempenho (KPIs) climáticos. Estas métricas subdividem-se em dimensões térmicas, higrométricas, eólicas, de radiação ultravioleta e índices de sensação térmica indexada, estruturadas de modo a suportar análises visuais iterativas e a fundamentar processos complexos de tomada de decisão.

Para suportar o ciclo de vida analítico dos dados, adotou-se uma arquitetura analítica baseada no modelo *Medallion*, executada sobre a infraestrutura de armazenamento distribuído *Hadoop Distributed File System* (HDFS). O motor de processamento central é o *Apache Spark* (via *PySpark*), operado através do ambiente de desenvolvimento *Jupyter*.

A lógica de progressão dos dados é estritamente controlada: a camada *Bronze* preserva a integridade original das respostas da API em formato estruturado JSON; a camada *Silver* realiza a limpeza, tipagem e conversão colunar dos registos para o formato otimizado *Parquet*; e a camada *Gold* consolida as agregações temporais finais em matrizes diárias e mensais prontas para consumo analítico. Complementarmente, sobre a camada final, foi construído um módulo de visualização interativa (incluindo a renderização cartográfica de um *HeatMap* distrital) e explorou-se a vertente preditiva através de modelos de *Machine Learning* focados na estimativa da temperatura média com base em variáveis de posicionamento e componentes de sazonalidade cíclica, avaliando o potencial da solução como ferramenta de previsão meteorológica.

Tecnologias e Ferramentas de Suporte

A solução aplica as tecnologias e técnicas abordadas na unidade curricular, organizadas segundo o Modelo Medallion (bronze - silver - gold). O **Spark** corre localmente e comunica pela rede com os dados, que residem no **HDFS**. Esta separação em camadas isola responsabilidades, permite reprocessar uma camada sem afetar as restantes e garante rastreabilidade do dado original até ao KPI final.

O armazenamento usa o **Hadoop/HDFS**, escolhido pela capacidade de guardar grandes volumes de forma distribuída e tolerante a falhas, com cada camada num diretório próprio. O processamento é feito com **Apache Spark (PySpark)**, recorrendo à API de DataFrames para ler a bronze, limpar e agregar na silver e calcular os indicadores na gold, pela eficiência do processamento distribuído. A componente preditiva usa o **Spark MLlib**, com os mesmos elementos dos exercícios de aula (VectorAssembler, modelos de regressão e separação treino/teste com avaliação por métricas).

O formato de armazenamento intermédio e final escolhido foi o **Apache Parquet**. Sendo um formato de armazenamento colunar e altamente comprimido, o Parquet reduz drasticamente o espaço em disco e otimiza o desempenho das consultas ao permitir a leitura seletiva de colunas (projetos), evitando o varrimento completo das linhas. Associado ao formato Parquet, implementou-se uma estratégia de **particionamento lógico** indexada à variável cronológica year_month. Esta organização física dos dados no HDFS garante que cada mês de observações seja armazenado num diretório exclusivo, acelerando os filtros temporais nas interfaces de visualização e tornando as rotinas de atualização altamente eficientes.

Ciclo de Processamento de Dados

A gestão do fluxo de dados segue, como referido, os princípios de uma arquitetura Medallion, organizando a informação em três níveis de maturidade e refinamento decrescente de ruído. Esta abordagem isola as responsabilidades de cada etapa, permitindo o reprocessamento integral de qualquer camada analítica sem necessitar de extrair novamente os dados originais.

Camada Bronze: fase de ingestão de dados em bruto

A etapa inicial do pipeline foca-se na extração sistemática e na preservação da integridade dos dados meteorológicos diretos. A recolha é efetuada a partir da API premium *Weatherstack*, aplicando pedidos HTTP parametrizados através do script ***historical_bronze.py***. Este módulo realiza chamadas iterativas para cada um dos 18 distritos de Portugal continental, capturando o histórico cronológico a partir de 01-01-2025. Os dados são inicialmente guardados num ambiente local temporário e, aquando da primeira execução do script de atualização do ecossistema (***user_update.py***), são transferidos definitivamente para o HDFS em formato JSON puro, garantindo o princípio da imutabilidade dos dados de origem.

O documento JSON devolvido pela API subdivide-se em três estruturas principais (Anexo 1):

- **location**: Agrupa os metadados geográficos da consulta, tais como o nome formal da região, as coordenadas geográficas precisas (latitude e longitude) e o fuso horário local.
- **current**: Contém um registo instantâneo e pontual das condições meteorológicas no momento exato da chamada da API.
- **historical**: Fornece a verdadeira dimensão temporal do projeto, agregando resumos diários estruturados por data com métricas explícitas como temperaturas extremas (mintemp, maxtemp), médias, horas de sol, índices ultravioleta e dados astronómicos.

A análise crítica da API revelou que o bloco **current** apresentava dados repetitivos e redundantes para análises históricas retroativas, pelo que foi inteiramente descartado nas fases seguintes. O foco analítico centrou-se exclusivamente no bloco **historical**.

Para além dos resumos diários, o bloco histórico contém o array hierárquico hourly, detalhando as observações hora a hora. Variáveis meteorológicas vitais como o volume de precipitação, a taxa de humidade e a velocidade do vento (incluindo as rajadas máximas) apenas são disponibilizadas pela API dentro desta estrutura horária. Por este motivo, configurou-se obrigatoriamente o parâmetro hourly=1 com um intervalo de amostragem definido em interval=1 no código de extração. Se o valor por omissão (0) tivesse sido mantido, o array horário seria omitido pela API, resultando na perda irreversível destes indicadores. Esta configuração aumentou a densidade informativa de cada ficheiro JSON sem introduzir custos adicionais no volume de chamadas permitidas pela API. Os ficheiros finais são armazenados no HDFS organizados por subdiretórios hierárquicos indexados pelo ano, mês e distrito correspondente.

Camada Silver: fase de limpeza, normalização e estruturação

A camada Silver realiza a conversão dos dados semiestruturados em bruto para uma base analítica perfeitamente limpa. Esta fase é executada pelo script ***generate_silver_hdfs***, que lê as estruturas JSON da camada Bronze, extrai as variáveis de interesse e consolida a informação num ficheiro único unificado em formato Parquet para a totalidade dos 18 distritos, segmentado por mês e ano.

O primeiro critério de normalização aplicado nesta fase consistiu na definição da granularidade temporal. Fixou-se uma granularidade estritamente diária (uma única linha por distrito e por dia), estabelecendo a unidade fundamental para todas as análises cronológicas subsequentes do projeto. Para convergir as variáveis horárias da camada anterior para esta nova escala diária, aplicaram-se agregações matemáticas específicas no Spark (Anexo 2): operou-se o somatório acumulado (sum) para a precipitação total diária, e calcularam-se as médias (avg) e os máximos absolutos (max) para os vetores de humidade, velocidade do vento e rajadas. As métricas que já se encontravam nativamente consolidadas ao nível diário na API foram mapeadas diretamente.

A seleção de campos foi estritamente guiada pelos KPIs desenhados pelo grupo, eliminando variáveis exógenas sem interesse analítico para otimizar a performance. Adicionalmente, implementaram-se duas correções técnicas críticas nesta fase:

1. **Extração Regular da Identidade Regional:** Detetou-se que o campo nominal do distrito devolvido pela API sofria de inconsistências textuais. Para contornar esta falha, a identidade do distrito passou a ser extraída diretamente do caminho do ficheiro (URI) no HDFS através de expressões regulares (F.regexp_extract). Adicionalmente, aplicou-se uma substituição de caracteres para eliminar a codificação de URL %20 em distritos com nomes compostos (Viana do Castelo, Castelo Branco e Vila Real), mapeando-os com espaços literais (Anexo 3).
2. **Imposição de Esquema Explícito:** Para mitigar falhas de inferência automática do Spark - que tendia a classificar a coluna da precipitação como um tipo inteiro (IntegerType) caso o primeiro registo lido correspondesse a um dia seco (valor 0), gerando valores nulos (null) nos dias de chuva subsequentes com valores decimais -, forçou-se a aplicação de um esquema manual rígido, tipificando todas as colunas numéricas de natureza contínua como DoubleType.

Camada Gold: métricas e KPIs

A camada Gold constitui o nível de maturidade máxima do pipeline, sendo responsável por ler os dados limpos da camada Silver e computar os Indicadores Chave de Desempenho (KPIs) meteorológicos e climáticos. Esta informação é estruturada de forma bitemporal em duas tabelas de consumo analítico, gravadas em formato Parquet e particionadas dinamicamente pelo campo year_month.

A primeira tabela, denominada gold_daily, opera na granularidade de uma linha por distrito e dia, enriquecendo a série temporal com métricas derivadas e classificações lógicas baseadas em limites normativos internacionais:

- **Dimensão Térmica:** temp_max, temp_min, temp_media e amplitude_termica (diferença absoluta entre os extremos diários).
- **Dimensão Higrométrica:** humidade_media, humidade_max, humidade_min e amplitude_humidade.
- **Dimensão Eólica:** vento_media, vento_max, rajada_max e a variável categórica categoria_vento, que estratifica a intensidade eólica em quatro escalões: *fraco* (<=20 km/h), *moderado* (<=50 km/h), *forte* (<070 km/h) e *muito forte* (>70 km/h).
- **Radiação Ultravioleta:** uv_index acompanhado pela categoria_uv, estruturada segundo os limiares da Organização Mundial da Saúde (OMS): *baixo* (<=2), *moderado* (<=5), *alto* (<=7), *muito alto* (<=10) e *extremo* (>=11).
- **Fotoperíodo e Eficiência Solar:** sunhour, duracao_dia (calculada dinamicamente através do diferencial cronológico entre o nascer e o pôr do sol) e o aproveitamento_solar (rácio percentual entre as horas efetivas de sol e a duração teórica do fotoperíodo).
- **Precipitação:** precip_total.
- **Bioclimatologia (Sensações Térmicas):** heat_index (sensação de calor calculada através da equação do *National Weather Service* dos EUA, combinando temperatura máxima e humidade) e wind_chill (sensação de frio indexada à temperatura mínima e à velocidade do vento).
- **Variáveis Binárias de Controlo (Flags 0/1):** Ativação de alertas lógicos para a ocorrência de fenómenos específicos, nomeadamente dia_quente (>30ºC), dia_frio (<5ºC) dia_neve (>0 mm), dia_chuva (>0 mm) e dia_chuva_intensa (>10 mm).

A segunda tabela, designada gold_monthly, colapsa a linha temporal para a escala de um registo por distrito e mês, gerando agregações estatísticas secundárias, análises de variabilidade e métricas de diagnóstico climático de longo prazo:

- **Agregações Térmicas e Variabilidade:** Médias mensais dos extremos térmicos, amplitude_extrema_mes, amplitude_media_dia e o desvio-padrão da temperatura (temp_desvio), que quantifica a instabilidade térmica ao longo do mês.

- **Graus-Dia Acumulados (Indicadores Energéticos):** Cálculo de graus_dia_aquecimento (HDD) e graus_dia_arrefecimento (CDD). Estas métricas quantificam o desvio acumulado da temperatura média diária face ao limiar de conforto térmico de 18ºC, servindo como indicadores diretos para estimativa de consumo de energia e climatização de edifícios.
- **Dinâmicas de Extremos:** Identificação da maior_onda_calor (comprimento máximo da sequência de dias quentes consecutivos) e do maior_periodo_seco (sequência máxima de dias sem precipitação).
- **Contadores Mensais de Eventos:** Soma acumulada de todos os indicadores binários diários (ex.: contagem de dias ultravioleta alto, dias de vento forte, dias secos ou dias de chuva intensa).
- **Análise Comparativa:** Geração do ranking_temp (posicionamento ordinal do distrito na escala térmica nacional desse mês) e da anomalia_temp, que mede o desvio preciso da temperatura média do distrito face à média consolidada de todo o território continental para o período homólogo.

Rotinas de sincronização e atualização

Para garantir que o repositório analítico processe de forma contínua as novas observações temporais sem a necessidade de reprocessar o histórico consolidado, projetou-se um mecanismo de sincronização incremental encapsulado num script unificado denominado ***user_update.py***. Este módulo automatiza a progressão do dado ao longo das três camadas Medallion de forma linear numa única chamada operacional, escrevendo diretamente nos volumes distribuídos do Hadoop.

A lógica de execução assenta no princípio do processamento sob demanda (*on-demand*):

1. O script interroga a tabela Silver no HDFS para detetar a data máxima cronológica (max(date)) efetivamente gravada no sistema.
2. Esta âncora temporal é comparada com o dia-alvo (o último dia civil completo disponível na API).
3. Caso a diferença temporal seja nula, o script aborta a execução por ausência de dados novos, poupando recursos computacionais e acessos à API.
4. Detetando-se uma janela temporal em falta, o script isola estritamente os meses civis afetados por esse intervalo de dias.

Para os meses identificados como incompletos, o pipeline executa uma reconstituição controlada. É efetuada a extração dos blocos em falta da API, alimentando de imediato a camada Bronze. De seguida, os novos registos JSON e os blocos históricos do respetivo mês são lidos pelo Spark, reexecutando-se as rotinas de limpeza da camada Silver e o recálculo dos indicadores diários e mensais da camada Gold.

O fator crítico para a eficiência desta operação reside na estratégia de escrita em disco, governada pela funcionalidade de **substituição dinâmica de partições** (*dynamic partition overwrite*). Esta configuração instrui o Spark a reescrever única e exclusivamente as pastas físicas do HDFS correspondentes aos meses afetados pela atualização, deixando todas as partições dos meses anteriores intactas e blindadas contra corrupção de dados.

Para além disso, imediatamente antes da operação de escrita no sistema de ficheiros distribuído, aplica-se a transformação .coalesce(1) ao DataFrame do Spark. Esta operação força a consolidação de todas as tarefas de escrita num único nó de processamento por partição, assegurando que cada mês seja persistido no HDFS na forma de um único ficheiro Parquet compacto. Esta técnica previne o fenómeno de fragmentação de armazenamento (*small files problem*), mantendo a integridade estrutural e a performance de leitura do cluster Hadoop. Atualmente operado de forma manual, o script foi modularizado para permitir o agendamento automático por tarefas cronológicas, visando a total autonomia operacional da solução.

Interfaces Visuais

A exploração do ecossistema de indicadores da camada Gold é realizada através de dois notebooks analíticos baseados na biblioteca Pandas e em componentes visuais interactivos, permitindo ao utilizador interrogar a base de dados de forma dinâmica recorrendo a mecanismos de filtragem (*widgets*).

O primeiro módulo consiste no desenvolvimento de um **HeatMap Cartográfico Interativo de Portugal Continental**. Esta interface gera mapas coropléticos utilizando a biblioteca **Folium**, projetando a variação espacial da temperatura média mensal entre os distritos. O motor gráfico lê o DataFrame consolidado a partir do HDFS e cruza a informação alfanumérica com uma camada geométrica externa em formato **GeoJSON**, que delimita as fronteiras políticas dos 18 distritos portugueses.

O alinhamento posicional ocorre através da correspondência textual do nome do distrito purificado na camada Silver com as chaves geográficas do GeoJSON. O sistema calcula a escala de cores e pinta dinamicamente os polígonos distritais com base nos valores numéricos. A interface disponibiliza seletores interativos de ano e mês, redesenhando o mapa instantaneamente sempre que a janela de observação é alterada, permitindo diagnosticar padrões de assimetria térmica regional.

O segundo notebook constitui o painel analítico central dos indicadores climáticos (KPIs_Gold). Esta interface acede diretamente às tabelas gold_daily e gold_monthly no Hadoop e converte os dados estruturados em visualizações estatísticas multiplataforma, controladas por seletores dinâmicos de período e região:

- Gráficos de barras emparelhadas para comparar os extremos térmicos (temp_max vs temp_min) e o rácio volumétrico de dias quentes e frios por unidade geográfica (Anexo 4).
- Diagramas de distribuição higrométrica para mapear os máximos e mínimos de humidade relativa por distrito (Anexo 5).
- Gráficos de barras triplas para monitorização da dinâmica eólica, plotando em simultâneo a velocidade média do vento, a velocidade máxima registada e o limiar das rajadas de vento por região (Anexo 6).
- Modelos de linhas temporais contínuas focados na análise bioclimática, sobrepondo as curvas térmicas reais com as curvas de sensação térmica calculadas (heat_index e wind_chill) ao longo dos dias do mês selecionado (Anexo 7).

Complementarmente, as interfaces integram um módulo de visualização tabular direta (Anexos 8 e 9). Ao acionar os filtros, o utilizador pode inspecionar diretamente as matrizes numéricas subjacentes que alimentam as representações gráficas, garantindo a auditabilidade total dos resultados gerados pelo pipeline analítico.

Modelo Preditivo e Análise

Com o objetivo de validar o potencial analítico da base de dados histórica construída, implementou-se um módulo de modelação estatística supervisionada focado na estimativa da temperatura média diária de um determinado distrito. O desenho do modelo assenta na utilização de variáveis preditoras minimalistas e universais: a componente cronológica de sazonalidade e as coordenadas geográficas cartografadas (latitude e longitude), testando a capacidade da solução de aprender comportamentos climatológicos regionais.

O principal desafio de engenharia de atributos (*feature engineering*) residiu no tratamento da variável mensal. Mapear o mês de forma puramente linear como um indexador numérico de 1 a 12 introduziria uma distorção matemática severa no modelo, uma vez que algoritmos numéricos interpretariam o mês de dezembro (12) e o mês de janeiro (1) como pontos opostos e de distância máxima, ocultando a sua contiguidade temporal real no ciclo do inverno. Para solucionar esta barreira de descontinuidade, aplicou-se uma transformação cíclica bivariada baseada em funções trigonométricas (Seno e Cosseno).

Esta técnica projeta o vetor mensal num espaço bidimensional circular, garantindo que meses consecutivos mantenham a mesma distância euclidiana e permitindo aos algoritmos capturar a natureza oscilatória e não linear das curvas de temperatura ao longo das estações do ano.

A arquitetura de modelação foi desenvolvida sobre o ecossistema Spark MLlib. As variáveis preditoras processadas (mes_sin, mes_cos, lat e lon) foram consolidadas num vetor denso de características através da classe VectorAssembler. A base de dados foi cindida aleatoriamente em conjuntos independentes de treino e de teste, aplicando-se uma validação cruzada baseada nas métricas estatísticas do Erro Quadrático Médio Corporal (**RMSE**) e no Coeficiente de Determinação ($\mathbf{R^2}$).

O estudo comparou o desempenho de dois algoritmos distintos:

1. **Regressão Linear:** Apresentou uma performance base com um RMSE de aproximadamente 3,3ºC e um score R^2 de 0,70. A natureza estritamente linear do algoritmo limitou a sua capacidade de modelar com precisão as microvariações geográficas.
2. **Random Forest Regressor:** Demonstrou uma clara superioridade preditiva, consolidando um RMSE de cerca de 3,0ºC um R^2 posicionado em 0,75. Este ganho de performance fundamenta-se na capacidade intrínseca do Random Forest de construir árvores de decisão que capturam interações complexas e relações não lineares entre as coordenadas geográficas e as componentes sazonais sem necessidade de pressupostos de linearidade.

Do ponto de vista científico de análise de séries temporais, importa traçar as limitações estruturais deste modelo. Dispondo de um histórico de dados restrito a aproximadamente 1,5 anos de observações contínuas, o modelo padece da ausência de múltiplos ciclos anuais completos. Esta limitação impede o algoritmo de isolar e aprender componentes de tendência secular ou oscilações climáticas plurianuais, restringindo a sua eficácia à reprodução da

climatologia média sazonal da região. Consequentemente, o modelo falha na captura do ruído meteorológico de curto prazo (como a passagem repentina de frentes frias ou depressões atlânticas), cujos fatores causais dinâmicos não estão contidos nas variáveis de posicionamento ou calendário.

Conclusão

O projeto académico executado atingiu plenamente os objetivos delineados, resultando na implementação bem-sucedida de um pipeline analítico ponta a ponta estruturado sobre os pilares da arquitetura Medallion e sustentado pelo ecossistema de computação distribuída Hadoop e Apache Spark. A operacionalização das camadas Bronze, Silver e Gold permitiu converter respostas brutas de uma API num repositório centralizado de Indicadores Chave de Desempenho climáticos de elevada granularidade, cobrindo os 18 distritos de Portugal continental. O sistema demonstrou robustez técnica ao integrar rotinas de atualização incremental baseadas em substituição dinâmica de partições, garantindo a escalabilidade e a manutenção autónoma da infraestrutura. As interfaces visuais interativas e o mapa coroplético comprovaram a utilidade prática da solução para apoiar processos de tomada de decisão baseados em dados meteorológicos contextuais.

O desenvolvimento prático consolidou competências essenciais em engenharia de dados à escala de Big Data. Evidenciou-se a necessidade imperativa de dominar em detalhe as especificidades e limitações das fontes de dados de origem (como demonstrado na rutura analítica entre os blocos instantâneos e históricos da API) e validou-se o impacto crítico de decisões de baixo nível - incluindo a dtype explícito de esquemas no Spark, a aplicação de coalescência para evitar a fragmentação de ficheiros e a purificação de cadeias de caracteres para o alinhamento de dados geográficos - na estabilidade de sistemas distribuídos.

Referências

- weatherstack - Real-Time & Historical World Weather Data API. Disponível em: https://weatherstack.com
- apilayer - APIs for developers (fornecedor da API weatherstack). Disponível em: https://apilayer.com
- Kaleko, D. - Feature Engineering: Handling Cyclical Features. Disponível em: https://blog.davidkaleko.com/feature-engineering-cyclical-features.html
- Kaggle - Cyclic Encoding: Sine and Cosine Transformations for Periodic Features. Disponível em: https://www.kaggle.com/general/491296

Anexos

```python
import os
import time
import calendar
import requests

API_KEY = "6fc53d10d52e414f5b9bd3fc669bca5c"

BASE = "/home/u2250055/project_weatherstack/bronze"

DISTRITOS = [
    "Aveiro", "Beja", "Braga", "Braganca", "Castelo Branco", "Coimbra",
    "Evora", "Faro", "Guarda", "Leiria", "Lisboa", "Portalegre",
    "Porto", "Santarem", "Setubal", "Viana do Castelo", "Vila Real", "Viseu",
]

# Intervalo de meses a extrair (inclusive).

START = (2025, 1)
END = (2026, 5)          # <-- mês 05-2026 incluído (último antes da entrega)

# hourly=1 captura o array horário, necessário para obter
# precipitação / humidade / vento ao nível diário no silver.

HOURLY = 1
INTERVAL = 1    #para obter os dados de todas as horas do dia

```

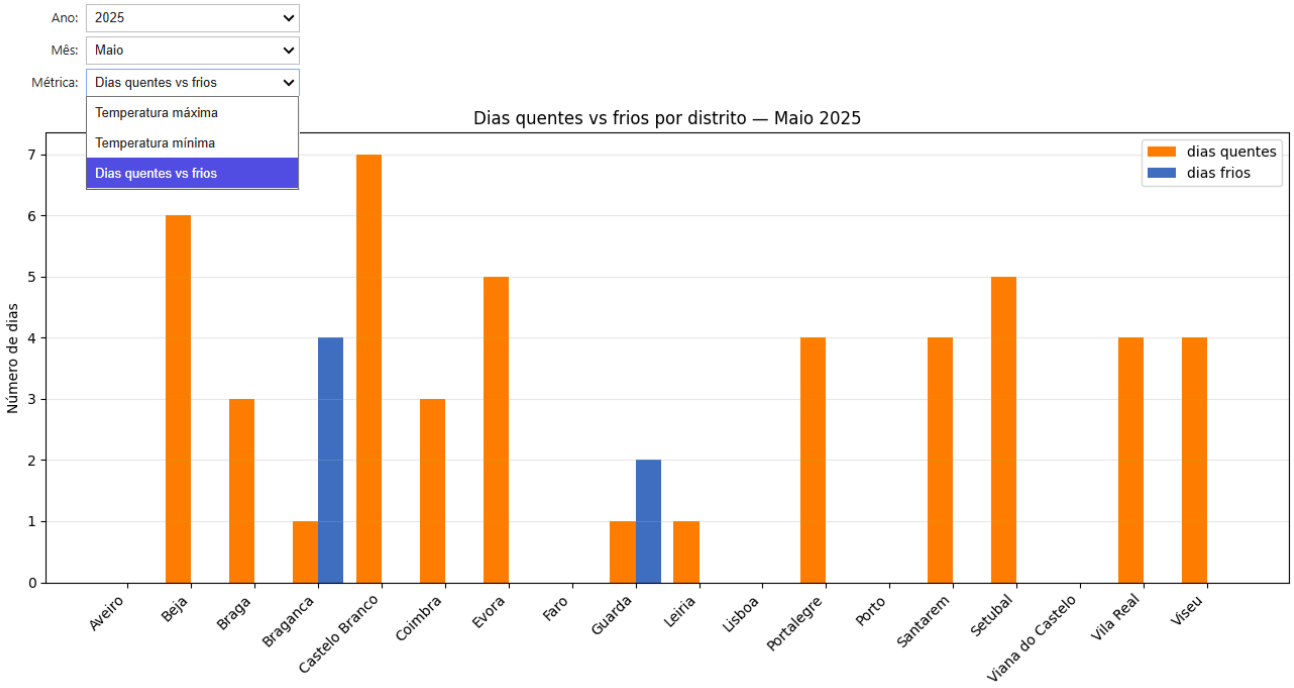
***Anexo 1** – Definição das variáveis HOURLY e INTERVAL para obter os dados de cada hora do dia*

```python
agg = horas.groupBy("district", "date").agg(
    F.round(F.sum("precip"), 2).alias("precip_total"),        # <- SOMATÓRIO da precipitação
    F.round(F.avg("humidity"), 1).alias("humidity_media"),    # <- MÉDIA da humidade
    F.max("humidity").alias("humidity_max"),                  # <- MÁXIMO da humidade
    F.min("humidity").alias("humidity_min"),                  # <- mínimo da humidade
    F.round(F.avg("wind_speed"), 1).alias("wind_media"),      # <- MÉDIA do vento
    F.max("wind_speed").alias("wind_max"),                    # <- MÁXIMO do vento
    F.max("windgust").alias("rajada_max"),                    # <- MÁXIMO da rajada
)
```

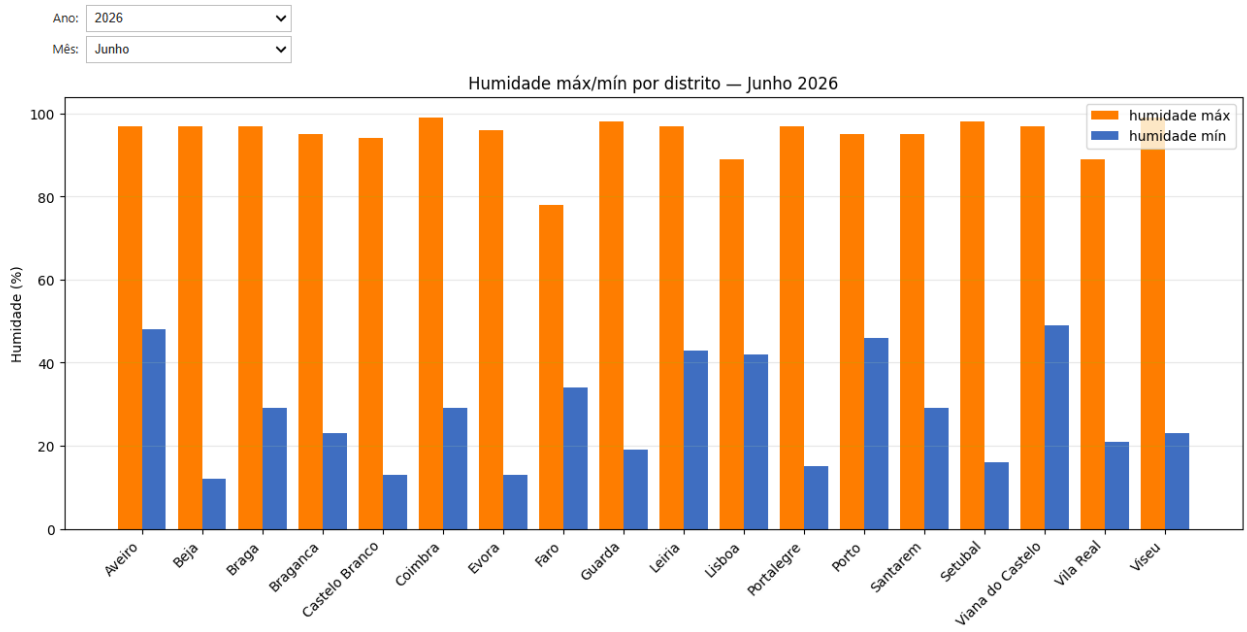
***Anexo 2 -** Conversão dos dados por hora num único valor*

```python
dias = df.select(
    F.regexp_replace(F.regexp_extract(F.col("_src"), r"distrito=([^/]+)/", 1), "%20", " ").alias("district"),
    F.col("location.country").alias("country"),
    F.col("location.lat").cast("double").alias("lat"),
    F.col("location.lon").cast("double").alias("lon"),
    F.explode("hist_map").alias("date_str", "dia"),
)
```

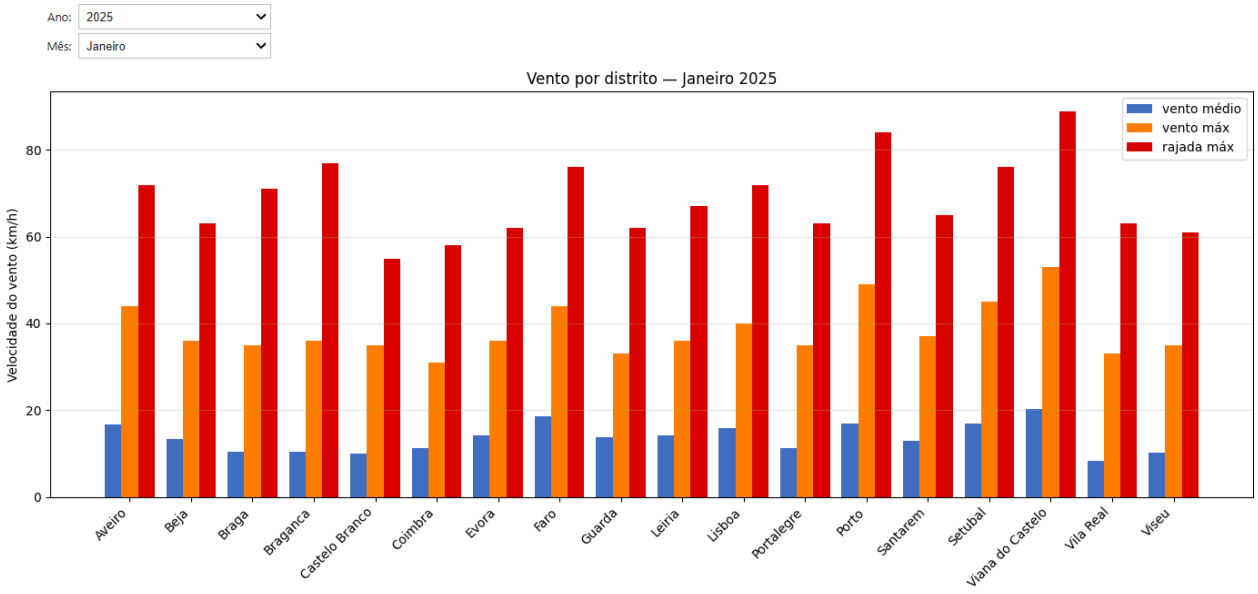
***Anexo 3 -** %20 para tratamento de espaços*



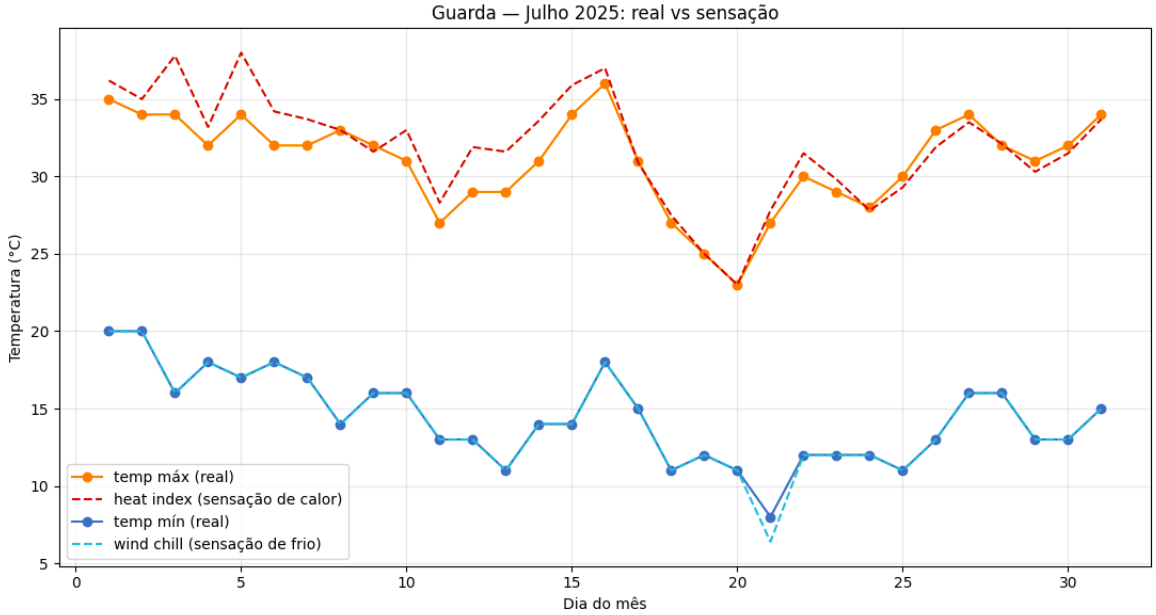
Anexo 4 - *Gráficos disponíveis relativamente a dados de Temperatura*



Anexo 5 - *Gráfico disponível relativamente a dados da Humidade*



Anexo 6 - *Gráfico disponível relativamente a dados do Vento*



Anexo 7 - *Gráfico disponível relativamente a dados de sensação térmica*

Tipo: Temperatura
Distrito:
Mes:

Temperatura
Humidade
Vento
UV
Sol/Luz
Precipitacao
Sensacoes
Flags

	da			media	amplitude_termica
0	2025-01-			10.0	8.0
1	2025-01-			11.0	7.0
2	2025-01-			12.0	6.0
3	2025-01-			13.0	7.0
4	2025-01-			14.0	4.0
5	2025-01-06	13.0	10.0	12.0	3.0
6	2025-01-07	15.0	10.0	13.0	5.0
7	2025-01-08	14.0	12.0	13.0	2.0
8	2025-01-09	16.0	12.0	14.0	4.0
9	2025-01-10	16.0	11.0	14.0	5.0
10	2025-01-11	17.0	13.0	15.0	4.0
11	2025-01-12	17.0	9.0	13.0	8.0
12	2025-01-13	15.0	7.0	11.0	8.0
13	2025-01-14	14.0	5.0	10.0	9.0
14	2025-01-15	12.0	4.0	8.0	8.0

Anexo 8 - *Opções de visualização de tabelas diárias*

Tipo: Temperatura
Mes:

Temperatura
Humidade
Vento
UV
Sol/Luz
Precipitacao
Sensacoes
Contagens (dias)
Comparativos

			in_mes	temp_media_mes	amplitude_extrema_mes	amplitude_media_dia	temp_desvio	graus_dia_aquecimento	graus_dia_arrefecimento	maior_onda_calor
0			4.0	11.9	13.0	5.6	1.82	190.0	0.0	0
1			2.0	11.8	17.0	7.4	2.23	193.0	0.0	0
2			2.0	10.1	15.0	6.4	2.20	245.0	0.0	0
3	Br		-2.0	6.2	17.0	7.8	1.99	366.0	0.0	0
4	Castelo		0.0	9.5	18.0	7.4	2.29	263.0	0.0	0
5	C		1.0	10.9	16.0	7.8	2.08	221.0	0.0	0
6			2.0	10.9	16.0	7.5	2.35	219.0	0.0	0
7	Faro	19.0	8.0	14.5	11.0	3.6	1.93	107.0	0.0	0
8	Guarda	14.0	-2.0	6.6	16.0	6.1	2.11	354.0	0.0	0
9	Leiria	17.0	3.0	11.5	14.0	6.5	2.10	201.0	0.0	0
10	Lisboa	18.0	5.0	13.2	13.0	4.9	2.18	150.0	0.0	0
11	Portalegre	16.0	1.0	9.2	15.0	6.1	2.11	272.0	0.0	0
12	Porto	16.0	6.0	11.9	10.0	4.0	1.77	188.0	0.0	0

Anexo 9 - *Opções de visualização de tabelas mensais*